

Projet Data Analyst Industriel

Dashboard industriel de suivi qualité et maintenance prédictive

Détection des défauts machines, analyse des paramètres techniques et priorisation des actions de maintenance

Auteur : Yunier Martir Prado | Portfolio Data Analyst Industriel | Suisse romande

Outils : Python, Visual Studio Code, SQLite, SQL, Power BI, DAX

Positionnement portfolio : ce projet démontre une capacité à transformer des données techniques machines en indicateurs exploitables pour la production, la qualité et la maintenance, avec une logique de maintenance prédictive basée sur des signaux techniques et des seuils d'alerte.

Version finale du rapport - Projet portfolio Data Analyst industriel

Résumé exécutif

Ce projet analyse un dataset industriel de maintenance prédictive composé de 10 000 observations machines. L'objectif est de comprendre les facteurs associés aux pannes, d'identifier les seuils de risque et de construire un dashboard Power BI permettant aux équipes techniques de prioriser les actions de maintenance avant l'apparition d'une défaillance.

Indicateur clé	Résultat
Observations analysées	10 000
Pannes confirmées	339
Taux global de panne	3,39 %
Impact économique simulé	169 500 CHF, sur hypothèse analytique de 500 CHF par panne
Observations sans panne	9 661
Observations sans signal technique	6 772, soit 67,72 % du dataset
Alertes préventives avant panne	2 924 observations
Priorité prédictive très élevée	36 observations sans panne cumulant 3 signaux techniques

Message principal : le risque de panne augmente fortement à partir de 180 minutes d'usure outil et devient critique à partir de 220 minutes, où le taux de panne atteint 24,11 %. Les profils combinant usure élevée, couple mécanique élevé et conditions thermiques HDF doivent être traités en priorité.

Sommaire

1. Contexte industriel et objectif business
2. Description du dataset et dictionnaire des variables
3. Préparation et nettoyage des données avec Python
4. Validation SQL et indicateurs de base
5. Analyse des résultats industriels
6. Évolution de la logique d'alerte et classification du risque
7. Dashboard Power BI : structure et logique de décision
8. Interprétation opérationnelle et plan d'action
9. Limites du projet et pistes d'amélioration
10. Conclusion finale et valeur portfolio
11. Annexes

1. Contexte industriel et objectif business

Ce projet s'appuie sur un jeu de données public de référence en maintenance prédictive, utilisé pour construire un cas d'analyse industriel réaliste dans un environnement de production. Le scénario retenu est celui d'une entreprise de fabrication située en Suisse romande, confrontée aux enjeux classiques de performance machine, de disponibilité des équipements, de qualité de production et de maîtrise des coûts liés aux arrêts non planifiés.

Dans un environnement de production de précision, les arrêts machines, les défauts de qualité et l'usure des composants peuvent générer des coûts importants, ralentir la production et réduire la disponibilité des équipements.

L'objectif du projet est d'analyser les données de fonctionnement machine afin d'identifier les paramètres associés aux défaillances, de construire des règles de surveillance préventive et de visualiser les priorités d'intervention dans un dashboard Power BI. Le projet ne prétend pas représenter les données confidentielles d'une entreprise réelle ; il transpose un dataset industriel public dans un contexte opérationnel proche des problématiques rencontrées en maintenance, production et amélioration continue.

1.1 Problème à résoudre

Les arrêts machines, les défaillances techniques et l'usure des composants peuvent réduire la disponibilité des équipements, générer des coûts de non-qualité et perturber la continuité de la production.

Le problème principal consiste donc à identifier les conditions techniques associées aux pannes afin de mieux anticiper les situations à risque. L'enjeu est de transformer les données de fonctionnement machine en indicateurs opérationnels permettant aux équipes de maintenance, production et qualité de prioriser les contrôles, les inspections et les actions préventives.

1.2 Tâche analytique / Business task

Analyser les données de maintenance d'un environnement industriel pour identifier les facteurs de panne, définir des seuils de risque et concevoir un tableau de bord d'aide à la décision destiné aux équipes production, qualité et maintenance.

1.3 Parties prenantes / Stakeholders

Dans un projet de maintenance prédictive appliqué à un environnement industriel, l'analyse des données doit répondre aux besoins de plusieurs acteurs opérationnels. Les principales parties prenantes concernées sont les suivantes :

- Responsable production : suit la continuité de la production, la disponibilité des équipements et l'impact des arrêts machines sur les objectifs opérationnels.
- Responsable maintenance : utilise les indicateurs techniques pour identifier les machines ou situations à risque, prioriser les interventions préventives et réduire les pannes non planifiées.
- Responsable qualité / amélioration continue : analyse les causes de défaillance, les effets sur la qualité du processus et les opportunités d'amélioration continue.

- Direction opérationnelle : évalue l'impact global des pannes sur la performance industrielle, les coûts estimés et la prise de décision stratégique.
- Techniciens de maintenance : exploitent les alertes, les seuils techniques et les priorités d'intervention pour organiser les contrôles terrain et les actions correctives ou préventives.

1.4 Questions analytiques

- 1) Quel est le taux global de panne et comment varie-t-il selon les types de produits L, M et H ?
- 2) Quel est l'impact économique estimé des pannes machines ?
- 3) Quels paramètres techniques sont les plus associés aux pannes ?
- 4) À partir de quel niveau d'usure outil le risque de panne augmente-t-il ?
- 5) Quelles causes de défaillance doivent être priorisées ?
- 6) Comment classer les observations en Normal, Alerte et Critique pour soutenir la priorisation opérationnelle ?

2 Description du dataset et dictionnaire des variables

Cette phase est dédiée à l'identification, l'acquisition et la compréhension du jeu de données utilisé dans le projet. Elle comprend la vérification de la source, l'évaluation de la qualité des données, l'analyse des limites du dataset et la description des principales variables techniques exploitées dans le dashboard.

2.1 Source et description des données

Le projet utilise le dataset industriel de maintenance prédictive AI4I 2020, disponible sur le dépôt UCI Machine Learning Repository. Il s'agit d'un jeu de données public de référence, conçu pour simuler un environnement industriel réaliste de production et de maintenance prédictive.

Le dataset contient 10 000 observations, représentant des cycles de fonctionnement d'équipements industriels. Il comprend des variables techniques issues de capteurs ou de paramètres machine, telles que la température de l'air, la température du processus, la vitesse de rotation, le couple mécanique, l'usure de l'outil et les indicateurs de défaillance.

Ce jeu de données permet d'analyser les relations entre les conditions de fonctionnement machine et les différents types de pannes, dans une logique proche des problématiques rencontrées en maintenance industrielle, production et amélioration continue.

2.2 Évaluation de la qualité de la source

Le dataset a été évalué selon une logique ROCCC afin de vérifier sa pertinence pour un projet de portfolio Data Analyst :

- Reliable / Fiable : le dataset provient d'un dépôt académique reconnu, largement utilisé pour des projets d'apprentissage, de démonstration et d'analyse de données.
- Original : les données sont structurées autour de paramètres techniques cohérents avec un environnement de production industrielle.
- Comprehensive / Complet : le dataset contient 10 000 observations et plusieurs types de défaillances, ce qui permet une analyse statistique exploitable.

- Current / Actuel : les principes physiques liés à la température, la vitesse de rotation, le couple mécanique et l'usure outil restent pertinents pour l'analyse de machines industrielles modernes.
- Cited / Cité : la source est publique, identifiable et adaptée à un usage pédagogique, analytique et de portfolio professionnel.

2.3 Éthique, confidentialité et sécurité des données

Le dataset ne contient aucune donnée personnelle, aucune information nominative, aucune donnée client et aucune information confidentielle appartenant à une entreprise réelle. Son utilisation ne présente donc pas de risque RGPD ni de problème de confidentialité industrielle.

Dans ce projet, les données sont utilisées exclusivement à des fins d'analyse, de visualisation et de démonstration professionnelle.

2.4 Limites identifiées

Le dataset ne contient pas de variables temporelles explicites, comme des dates ou des heures d'intervention. L'identifiant UDI permet de suivre l'ordre des observations, mais ne permet pas de réaliser une analyse temporelle complète.

De plus, les coûts financiers ne sont pas intégrés dans la source originale. L'estimation économique des pannes repose donc sur une hypothèse de coût unitaire, utilisée uniquement pour donner une lecture business de l'impact potentiel des défaillances.

Enfin, le projet applique une logique de surveillance prédictive basée sur des règles techniques et des seuils d'alerte. Il ne s'agit pas d'un modèle de machine learning avancé, mais d'un système d'aide à la décision destiné à prioriser les situations à risque.

2.5 Format de stockage et copie de travail

Les données d'origine sont disponibles au format CSV, ce qui facilite leur traitement avec Python, SQL et Power BI. Avant toute transformation, une copie de travail a été créée afin de préserver le fichier original et de structurer le projet de manière professionnelle.

Le fichier nettoyé a ensuite été sauvegardé sous le nom `machine_failures_clean.csv` pour être utilisé dans les étapes suivantes d'analyse, de validation SQL et de construction du dashboard Power BI.

Élément	Description
Volume initial	10 000 observations
Variables initiales	14 variables principales
Format	CSV
Nature des données	Mesures techniques de fonctionnement machine et indicateurs de défaillance
Données personnelles	Aucune donnée personnelle, aucun client, aucun employé, aucune information confidentielle
Limites structurelles	Absence de Machine_ID réel, absence d'horodatage et absence d'historique de maintenance

2.6 Paramètres de la base de données

Variable source	Nom métier en français	Utilité analytique
UDI	Identifiant unique de l'observation	Identifie chaque cycle machine dans le dataset.
Product ID	Identifiant produit	Identifie le produit associé à l'observation.
Type	Type de produit	Catégorie L, M ou H.
Air temperature [K]	Température de l'air ambiant (K)	Température extérieure autour du processus.
Process temperature [K]	Température du processus (K)	Température interne liée au fonctionnement machine.
Rotational speed [rpm]	Vitesse de rotation (tr/min)	Régime de rotation du composant mécanique.
Torque [Nm]	Couple mécanique (Nm)	Charge ou effort mécanique exercé.
Tool wear [min]	Usure outil (min)	Usure cumulée de l'outil.
Machine failure	Panne machine	Indicateur binaire : 1 = panne, 0 = sans panne.
TWF	Défaillance liée à l'usure outil	Tool Wear Failure.
HDF	Défaillance de dissipation thermique	Heat Dissipation Failure.
PWF	Défaillance de puissance	Power Failure.
OSF	Surcharge mécanique	Overstrain Failure.
RNF	Défaillance aléatoire	Random Failure.

3. Préparation et nettoyage des données avec Python

La préparation des données a été réalisée avec un script Python exécuté dans Visual Studio Code. Ce choix permet de mettre en place un pipeline reproductible, traçable et plus professionnel qu'un nettoyage manuel réalisé directement dans un tableur.

L'objectif de cette phase est de transformer le fichier brut en un dataset propre, exploitable pour l'analyse SQL et la construction du dashboard Power BI. Le script Python permet de lire le fichier original, de créer de nouvelles variables techniques, de standardiser les noms de colonnes, de contrôler la qualité des données et d'exporter un fichier propre dans une structure de projet organisée.

L'utilisation de Python présente plusieurs avantages dans ce projet :

- reproductibilité : les transformations peuvent être relancées à tout moment à partir du fichier source ;
- traçabilité : chaque opération de nettoyage est documentée dans le script ;
- fiabilité : les étapes de transformation ne dépendent pas de manipulations manuelles ;
- compatibilité : le fichier final est préparé pour être utilisé ensuite avec SQL et Power BI.

3.1 Transformations réalisées

Les principales transformations réalisées lors de cette phase sont les suivantes :

1. Conversion des températures de Kelvin en degrés Celsius, avec la création des variables `Air_temperature_C` et `Process_temperature_C`.
2. Création de la variable `Temperature_Delta_C`, représentant l'écart thermique entre la température du processus et la température de l'air.
3. Renommage des colonnes techniques dans un format standardisé compatible avec SQL et Power BI : `Rotational_speed_rpm`, `Torque_Nm`, `Tool_wear_min` et `Machine_failure`.
4. Vérification des dimensions du dataset afin de contrôler le nombre de lignes et de colonnes après transformation.
5. Contrôle des doublons et des valeurs nulles par colonne afin d'identifier d'éventuels problèmes de qualité des données.
6. Exportation du fichier propre sous le nom `machine_failures_clean.csv` dans le dossier `02_cleaned_data`.

Voici un extrait du rapport de validation généré dans le terminal VS Code, confirmant la structure finale du dataset après nettoyage : 10 000 observations et 17 variables.

Nombre de doublons avant suppression : 0

Nombre de doublons après suppression : 0

Contrôle qualité réussi : fichier généré `machine_failures_clean.csv`

Structure finale du dataset : (10000, 17)

Valeurs nulles détectées : 0 sur les variables utilisées

STATUS : Validation terminée - fichier nettoyé prêt pour SQL et Power BI

3.2 Choix techniques et logique de préparation

Le choix de convertir les températures en degrés Celsius permet de rendre les mesures plus lisibles pour un public industriel européen. Les valeurs initiales en Kelvin sont pertinentes d'un point de vue scientifique, mais moins intuitives pour l'interprétation opérationnelle dans un contexte de maintenance, production ou qualité.

La variable `Temperature_Delta_C` a été créée afin d'analyser l'écart entre la température du processus et la température de l'air. Cette variable est utile pour étudier les comportements thermiques associés à certaines défaillances, notamment les profils de type HDF liés à la dissipation thermique.

Le renommage des colonnes répond à un objectif de standardisation. Les noms d'origine contenant des espaces, des crochets ou des unités peuvent être moins pratiques à manipuler dans SQL, Power BI ou DAX. Des noms plus courts et explicites facilitent l'écriture des requêtes, la création des mesures et la maintenance du projet.

Le fichier original n'a pas été modifié directement. Une copie de travail a été utilisée afin de préserver la source initiale et de garantir une séparation claire entre les données brutes et les données nettoyées.

3.3 Contrôle qualité des données

Un contrôle qualité simple a été réalisé à la fin du script afin de vérifier la structure du dataset après transformation. Ce contrôle comprend notamment :

- l'affichage des dimensions du dataset ;
- la vérification des valeurs nulles par colonne ;
- le contrôle des doublons avant et après suppression ;
- la cohérence des nouvelles variables créées ;
- la validation du fichier exporté pour les étapes SQL et Power BI.

Le contrôle qualité confirme une structure finale de 10 000 observations et 17 variables. Aucun doublon n'a été détecté dans le dataset après vérification avec Python. Le contrôle des valeurs nulles indique également l'absence de données manquantes dans les variables utilisées pour l'analyse.

Ces vérifications permettent de sécuriser la base de travail avant les étapes suivantes : validation SQL, création des mesures DAX et construction du dashboard Power BI.

3.4 Extrait contrôlé du script Python

Le rapport ne présente pas l'intégralité du script Python afin de conserver une lecture claire et orientée analyse. Le code complet est destiné à être fourni séparément dans le dépôt GitHub du projet.

Extrait du script 02_nettoyage_donnees.py :

```
df['Air_temperature_C'] = df['Air temperature [K]'] - 273.15
df['Process_temperature_C'] = df['Process temperature [K]'] - 273.15
df['Temperature_Delta_C'] = df['Process_temperature_C'] - df['Air_temperature_C']

df.rename(columns={
    'Rotational speed [rpm]': 'Rotational_speed_rpm',
    'Torque [Nm]': 'Torque_Nm',
    'Tool wear [min]': 'Tool_wear_min',
    'Machine failure': 'Machine_failure'
}, inplace=True)

print("Nombre de doublons avant suppression :", df.duplicated().sum())

df = df.drop_duplicates()

print("Nombre de doublons après suppression :", df.duplicated().sum())

df.to_csv(output_path, index=False)

print(df.shape)
print(df.isnull().sum())
```

Ce fragment illustre les principales opérations de préparation : conversion des unités, création d'une variable technique, standardisation des noms de colonnes, contrôle des doublons, export du fichier nettoyé et vérification simple de la structure et des valeurs nulles.

3.5 Structure de projet recommandée

Afin de séparer clairement les fichiers sources, les fichiers transformés, les scripts et les livrables, le projet est organisé selon la structure suivante :

Dossier | Rôle

01_raw_data | Fichier CSV original non modifié.

02_cleaned_data | Fichier machine_failures_clean.csv généré par Python.

03_sql | Base SQLite maintenance_industrielle.db et requêtes SQL de validation.

04_python | Script 02_nettoyage_donnees.py.

05_powerbi | Dashboard Power BI au format .pbix.

06_rapport | Rapport final DOCX/PDF et captures du dashboard.

Cette organisation permet de présenter le projet comme un workflow complet de Data Analyst, depuis la donnée brute jusqu'au dashboard final et aux recommandations opérationnelles.

4. Validation SQL et indicateurs de base

Après nettoyage, le fichier propre a été importé dans une base SQLite locale afin de valider la structure, contrôler le volume et calculer les premiers indicateurs industriels. Cette étape démontre la capacité à passer d'un fichier CSV à une base exploitable avec SQL avant la visualisation Power BI.

4.1 Contrôles de validation

- 1) Vérification des premières lignes : `SELECT * FROM maintenance_data LIMIT 10;`
- 2) Vérification du nombre total d'observations : `SELECT COUNT(*) FROM maintenance_data;`
- 3) Vérification du schéma : `PRAGMA table_info(maintenance_data);`
- 4) Contrôle de cohérence entre les agrégations SQL et les KPI du dashboard.

4.2 KPI de base

KPI	Résultat	Interprétation
Total observations	10 000	Population totale analysée.
Total pannes	339	Nombre d'observations avec Machine_failure = 1.
Taux global de panne	3,39 %	339 / 10 000.
Observations sans panne	9 661	Observations avec Machine_failure = 0.
Coût estimé des pannes	169 500 CHF	Hypothèse analytique de 500 CHF par panne.

5. Analyse des résultats industriels

5.1 Performance par type de produit

Type	Observations	Pannes	Taux de panne	Coût estimé
L	6 000	235	3,92 %	117 500 CHF
M	2 997	83	2,77 %	41 500 CHF
H	1 003	21	2,09 %	10 500 CHF
Total	10 000	339	3,39 %	169 500 CHF

La catégorie L concentre le plus grand volume de pannes et l'impact économique estimé le plus élevé. Elle présente également le taux de panne le plus important, ce qui en fait une priorité d'analyse pour la production, la qualité et la maintenance.

5.2 Paramètres techniques associés aux pannes

Statut	Vitesse moyenne	Usure outil moyenne	Delta thermique moyen	Couple moyen
Sans panne	1 540,26 rpm	106,69 min	10,02 °C	39,63 Nm
Avec panne	1 496,49 rpm	143,78 min	9,40 °C	50,17 Nm

Les observations avec panne présentent un couple mécanique moyen plus élevé, une usure outil plus avancée et une vitesse de rotation moyenne plus faible. Le graphique de dispersion couple/vitesse confirme une zone mécanique à risque lorsque le couple est élevé et que la vitesse de rotation est plus faible.

5.3 Usure outil et seuils critiques

Plage d'usure	Observations	Pannes	Taux de panne	Recommandation
0–59 min	2 810	58	2,06 %	Surveillance normale
60–119 min	2 737	70	2,56 %	Surveillance normale
120–179 min	2 733	56	2,05 %	Surveillance normale
180–219 min	1 579	121	7,66 %	Contrôle préventif
220 min et plus	141	34	24,11 %	Intervention prioritaire

Interprétation : le seuil de 180 min marque l'entrée dans une zone d'alerte. Le seuil de 220 min correspond à une zone critique où le taux de panne atteint 24,11 %. Il ne s'agit pas d'une réduction garantie de 24,11 %, mais d'une exposition à un niveau de risque beaucoup plus élevé.

5.4 Causes de défaillance

Cause	Traduction opérationnelle	Occurrences	Part des causes
HDF	Défaillance thermique	115	30,83 %
OSF	Surcharge mécanique	98	26,27 %
PWF	Défaillance de puissance	95	25,47 %
TWF	Usure outil	46	12,33 %
RNF	Défaillance aléatoire	19	5,09 %

HDF, OSF et PWF représentent ensemble 82,57 % des causes spécifiques enregistrées. Ces trois familles doivent guider la priorisation du plan d'action préventif.

6. Évolution de la logique d'alerte et classification du risque

La classification du risque n'a pas été fixée dès le départ. Elle a été améliorée progressivement après plusieurs consultations des résultats issus de la base de données. La première version utilisait une logique thermique trop simple, basée notamment sur une température de processus élevée. L'analyse complémentaire des HDF a montré que la température absolue était moins discriminante que la combinaison d'un delta thermique faible et d'une vitesse de rotation basse.

6.1 Ancienne logique thermique et correction

Étape	Condition étudiée	Conclusion
Version initiale	Température du processus élevée, par exemple $\geq 40\text{ }^{\circ}\text{C}$	Règle trop simple : elle ne capturerait pas correctement les profils HDF.
Analyse complémentaire	Comparaison HDF = 0 vs HDF = 1	HDF présente surtout un delta thermique plus faible et une vitesse plus basse.
Version finale	Temperature_Delta_C < 9,5 °C ET Rotational_speed_rpm < 1 400 rpm	Condition plus cohérente avec la logique de dissipation thermique.

6.2 Règles finales de classification

- 1) Critique : une panne machine est déjà enregistrée (Machine_failure = 1).
- 2) Alerte préventive : aucune panne n'est enregistrée, mais au moins un seuil technique d'alerte est dépassé.
- 3) Normal : aucune panne et aucun seuil d'alerte dépassé.

Signal technique	Condition finale d'alerte	Interprétation
Usure outil	Tool_wear_min ≥ 180 min	Détection d'un risque d'usure avancée.
Couple mécanique	Torque_Nm ≥ 50 Nm	Détection d'un effort mécanique élevé.
Profil HDF	Temperature_Delta_C < 9,5 °C ET Rotational_speed_rpm < 1 400 rpm	Détection d'un profil de dissipation thermique à risque.

6.3 Répartition finale des niveaux de risque

Niveau	Observations	Pannes	Part	Interprétation
Normal	6 737	0	67,37 %	Surveillance habituelle
Alerte	2 924	0	29,24 %	Surveillance renforcée ou action préventive
Critique	339	339	3,39 %	Intervention corrective et analyse de cause racine
Total	10 000	339	100,00 %	-

6.4 Signaux cumulés et priorité prédictive

Cumul de signaux	Observations sans panne	Part des alertes	Priorité
1 signal	2 465	84,30 %	Contrôle ciblé
2 signaux	423	14,47 %	Inspection prioritaire
3 signaux	36	1,23 %	Intervention préventive immédiate
Total alertes sans panne	2 924	100,00 %	File prédictive avant panne

Clarification importante : 67 observations cumulent 3 signaux au total, mais 31 sont déjà en panne. La priorité prédictive avant panne correspond donc aux **36 observations** sans panne cumulant les 3 signaux techniques.

7. Dashboard Power BI : structure et logique de décision

Le dashboard final est composé de trois pages. Chaque page répond à une étape de décision : comprendre la performance globale, analyser les facteurs techniques, puis prioriser les actions de maintenance prédictive.

Page	Contenu principal	Rôle décisionnel
Page 1 - Vue générale de la performance	KPI globaux, taux de panne par type de produit, impact économique, observations stables, synthèse par type.	Donner une vision business rapide de la performance industrielle.
Page 2 - Analyse technique des facteurs de panne et signaux d'alerte	Usure outil, causes HDF/OSF/PWF/TWF/RNF, scatter couple/vitesse, comparaison panne vs sans panne.	Identifier les paramètres techniques associés au risque.
Page 3 - Maintenance prédictive basée sur signaux techniques	Risque prédictif, alertes préventives, file prédictive avant panne, seuils d'alerte, plan d'action.	Transformer l'analyse en priorisation opérationnelle.

7.1 Indicateurs principaux du dashboard

- 1) Pannes totales : 339.
- 2) Coût estimé des pannes : 169 500 CHF.
- 3) Taux global de panne : 3,39 %.
- 4) Taux d'observations stables : 67,72 % des observations ne présentent aucun signal technique.
- 5) Risque prédictif : 3 228 observations avec au moins un signal technique.
- 6) Alertes préventives avant panne : 2 924 observations.
- 7) Priorité très élevée : 36 observations sans panne cumulant 3 signaux techniques.

8. Interprétation opérationnelle et plan d'action

La logique opérationnelle du projet est la suivante : **suivi qualité** → **analyse des pannes** → **signaux prédictifs** → **priorisation** → **plan d'action préventif**

8.1 Actions recommandées

Signal / cible	Action proposée	Équipe concernée
Usure outil ≥ 180 min	Planifier un contrôle préventif.	Maintenance
Usure outil ≥ 220 min	Prioriser l'intervention avant panne.	Maintenance / Production
Torque_Nm ≥ 50 Nm	Contrôler l'effort, la charge machine et les conditions d'utilisation.	Maintenance / Méthodes
Profil HDF	Surveiller température, ventilation, refroidissement et vitesse de rotation.	Maintenance / Qualité
Type L	Suivre plus étroitement la performance et	Production / Qualité

	les paramètres techniques associés.	
HDF, OSF, PWF	Concentrer les actions d'amélioration sur les trois causes dominantes.	Amélioration continue

Conclusion opérationnelle : appliquer les actions recommandées dans le plan d'action préventif afin d'intervenir avant la zone critique et de réduire l'exposition aux défaillances.

9. Limites du projet et pistes d'amélioration

- 1) Le dataset ne contient pas de Machine_ID : il n'est pas possible d'associer une alerte à un équipement physique précis.
- 2) Le dataset ne contient pas d'horodatage : il n'est pas possible d'analyser les tendances temporelles, la saisonnalité ou les cycles de maintenance.
- 3) Le coût de 500 CHF par panne est une hypothèse analytique et non une donnée comptable réelle.
- 4) Les seuils utilisés sont cohérents avec le dataset étudié, mais ils doivent être validés avec des données réelles, l'historique de maintenance et l'expertise terrain.
- 5) Le projet applique une logique prédictive basée sur des règles et signaux techniques. Il ne s'agit pas encore d'un modèle de machine learning avancé.

9.1 Évolutions possibles

- 1) Ajouter Machine_ID, date/heure, historique d'intervention, temps d'arrêt et coût réel de maintenance.
- 2) Construire un modèle supervisé de classification du risque de panne.
- 3) Calculer des indicateurs MTBF, MTTR, taux de disponibilité et coût de non-qualité.
- 4) Créer un score de risque dynamique et un système d'alerte par équipement.
- 5) Publier le dashboard dans Power BI Service avec actualisation planifiée.

10. Conclusion finale et valeur portfolio

Ce projet a permis de construire un cas complet d'analyse industrielle, depuis la préparation des données jusqu'à la création d'un dashboard Power BI orienté décision. À partir d'un jeu de données public de maintenance prédictive, l'objectif était de transformer des données techniques de fonctionnement machine en indicateurs opérationnels exploitables par les équipes de production, maintenance et qualité.

Les questions analytiques initiales ont permis de structurer l'ensemble du projet. L'analyse montre d'abord que le taux global de panne machine est de 3,39 %, avec 339 pannes observées sur 10 000 cycles de fonctionnement. La catégorie de produit L présente le taux de panne le plus élevé, avec 3,92 %, suivie des catégories M et H. Cette lecture permet d'identifier les familles de produits les plus exposées et de mieux cibler les efforts de surveillance.

L'impact économique estimé des pannes atteint 169 500 CHF, sur la base d'une hypothèse de 500 CHF par panne. Cette estimation ne représente pas un coût réel issu de l'entreprise, mais elle permet de donner une lecture business de l'impact potentiel des défaillances et de relier l'analyse technique à des enjeux de performance industrielle.

L'analyse des paramètres techniques met en évidence plusieurs facteurs associés aux pannes : l'usure de l'outil, le couple mécanique, la vitesse de rotation et les conditions thermiques. Le risque augmente

fortement à partir de 180 minutes d'usure outil, tandis que la zone critique est atteinte à partir de 220 minutes. Dans cette zone critique, le taux de panne atteint 24,11 %, ce qui en fait un seuil prioritaire pour la surveillance préventive.

L'analyse des causes de défaillance montre également que les causes HDF, OSF et PWF concentrent une part importante des défaillances. Ces résultats orientent les actions préventives vers trois axes principaux : la surveillance thermique, le contrôle de la surcharge mécanique et la stabilité du processus de puissance.

Le projet a également permis de construire une logique de classification des observations en trois niveaux: Normal, Alerte et Critique. Cette classification permet de distinguer les observations sans signal technique, les observations sans panne mais présentant un ou plusieurs signaux d'alerte, et les observations déjà associées à une panne. Les 36 observations sans panne cumulant trois signaux techniques représentent la priorité prédictive la plus élevée avant défaillance.

Ainsi, le dashboard répond aux questions initiales du projet en identifiant le taux de panne global, les catégories de produits les plus exposées, l'impact économique estimé, les paramètres techniques associés aux pannes, les seuils d'usure critiques, les principales causes de défaillance et les priorités d'intervention.

Sur le plan technique, ce projet démontre la capacité à préparer des données avec Python, valider des indicateurs avec SQL, construire des mesures DAX, concevoir un dashboard Power BI structuré et traduire des résultats analytiques en recommandations opérationnelles. Il ne s'agit pas seulement d'un exercice de visualisation, mais d'un workflow complet reliant données, maintenance industrielle, qualité, performance et aide à la décision.

La valeur portfolio de ce projet réside dans sa double dimension : technique et industrielle. Il montre une capacité à comprendre les contraintes du terrain, à interpréter des paramètres mécaniques tels que l'usure outil, le couple, la vitesse de rotation et les conditions thermiques, puis à les transformer en indicateurs compréhensibles pour des décideurs opérationnels.

Ce projet renforce ainsi un positionnement professionnel à l'intersection de la mécanique industrielle, de la maintenance, de la qualité et de la data analysis. Il constitue une preuve concrète de compétences transférables vers des rôles tels que Data Analyst industriel, technicien maintenance orienté data, analyste qualité, amélioration continue ou support performance industrielle en Suisse romande.


Le dashboard final ne se limite pas à observer les pannes. Il propose une logique d'aide à la décision : détecter les signaux, isoler les observations en alerte, identifier les priorités avant panne et proposer des actions préventives concrètes.

Annexe A - Formules et indicateurs clés

Indicateur	Logique	Interprétation
Taux global de panne	$\text{SUM}(\text{Machine_failure}) / \text{COUNTROWS}(\text{dataset})$	Mesure la fréquence globale de défaillance.
Taux panne zone critique	Pannes en $\text{Tool_wear_min} \geq 220$ / Observations en $\text{Tool_wear_min} \geq 220$	Mesure l'exposition au risque dans la zone critique.
Risque prédictif	$\text{nombre_signaux} \geq 1$	Identifie les observations avec au moins un signal technique.
Alerte préventive	$\text{Machine_failure} = 0$ et au moins un seuil d'alerte dépassé	Identifie les cas à surveiller avant panne.
Priorité très élevée	$\text{Machine_failure} = 0$ et $\text{nombre_signaux} = 3$	Priorité prédictive maximale avant défaillance.

Annexe B - Captures du dashboard Power BI

Page 1 - Vue générale de la performance



Page 2 - Analyse technique des facteurs de panne



Dashboard industriel de suivi qualité et maintenance prédictive

Page 2 - Analyse technique des facteurs de panne et signaux d'alerte



9 661

Obs sans panne KPI



2 924

Obs alerte KPI



HDF 30,83 %

Cause dominante



143,78 min


Usure moy en panne




50,17 Nm

Couple moy panne


Taux de panne par plage d'usure outil



Pareto des causes de défaillance



Zones mécaniques à risque : couple et vitesse de rotation




Comparaison des paramètres moyens selon le statut de panne

Statut panne	Vitesse moyenne rpm	Usure outil moyenne	Delta thermique moyen	Couple moyen Nm
Avec panne	1496,49	143,78	9,40	50,17
Sans panne	1540,26	106,69	10,02	39,63
Total	1538,78	107,95	10,00	39,99

Insight : Les trois principales causes concentrent **82,57 %** des défaillances observées :
défaillance thermique, surcharge mécanique et défaillance de puissance.

Répartition des causes de défaillance



Insight : Le risque de panne augmente fortement à partir de **180 minutes d'usure outil**, avec un niveau critique au-delà de **220 minutes**. Le croisement couple/vitesse met en évidence une zone de risque lorsque le **couple mécanique** est élevé et que la **vitesse de rotation** est relativement faible.

Activer W

Page 3 - Maintenance prédictive et plan d'action



Dashboard industriel de suivi qualité et maintenance prédictive

Page 3 - Maintenance prédictive basée sur des signaux techniques et des seuils d'alerte : priorisation des risques et plan d'action

339

Pannes totales

3 228

Obs. risque prédictif

2 924

Obs. Alertes préventives

≥ 220 min

Seuil critique d'usure

24,11 %

Taux panne zone critique

36 Obs.

Priorité très élevée

A) Priorité opérationnelle par type de produit

Type	Nb de pannes	Taux de panne	Coût estimé
L	235	3,92 %	117 500 CHF
M	83	2,77 %	41 500 CHF
H	21	2,09 %	10 500 CHF
Total	339	3,39 %	169 500 CHF

B) Plan d'intervention selon seuils prédictifs d'usure

Plage d'usure outil	Taux de panne	Recommandation
0-59 min	2,06 %	Surveillance normale
60-119 min	2,56 %	Surveillance normale
120-179 min	2,05 %	Surveillance normale
180-219 min	7,66 %	Contrôle préventif
220 min et plus	24,11 %	Intervention prioritaire

C) File prédictive avant panne

Cumul signaux affiché	Nb observations	Priorité signaux dynamique
3 signaux	36	Priorité très élevée
2 signaux	423	Priorité moyenne
1 signal	2465	Priorité faible
Total	2924	

D) Plan d'action préventif par cause de défaillance

Cause	Cause détaillée	Nb observations cause	Part cause (%)	Action recommandée	Priorité
HDF	Défaillance thermique	115	33,05 %	Surveiller température, ventilation et refroidissement	Élevée
OSF	Surcharge mécanique	98	28,16 %	Contrôler couple, charge machine et conditions d'effort	Élevée
PWF	Défaillance de puissance	95	27,30 %	Vérifier puissance, alimentation et stabilité du processus	Élevée
TWF	Usure outil	46	13,22 %	Planifier le remplacement de l'outil avant le seuil critique	Moyenne
RNF	Défaillance aléatoire	19	5,46 %	Réaliser des vérifications complémentaires et suivre la récurrence	

E) Seuils prédictifs d'alerte

Signal technique	Condition d'alerte	Interprétation	Action recommandée
Profil thermique HDF	Temperature_Delta_C < 9,5 °C et vitesse < 1 400 rpm	Risque de dissipation thermique	Surveiller température, ventilation et rotation
Seuil critique d'usure	Tool_wear_min ≥ 220 min	Risque critique de panne	Prioriser l'intervention avant panne
Usure outil	Tool_wear_min ≥ 180 min	Risque d'usure avancée	Planifier un contrôle préventif
Couple mécanique	Torque_Nm ≥ 50 Nm	Risque de surcharge mécanique	Contrôler l'effort et la charge machine



Filtres opérationnels



Type de produit

Niveau de risque

Tout

Tout

Plage d'usure outil

Type de panne

Tout

Tout



Appliquer les actions recommandées du tableau E afin d'intervenir avant la zone critique et réduire l'exposition aux défaillances.



F) Conclusion opérationnelle : 36 observations sans panne cumulent 3 signaux techniques : elles représentent la priorité prédictive la plus élevée avant défaillance.

Les actions doivent cibler le type L, les usures ≥ 180 min, la zone critique ≥ 220 min, les profils couple élevé / vitesse faible et les causes HDF, OSF et PWF.

Activer W

Annexe C - Script Python utilisé

```

import os

import pandas as pd

# 1. Chemins locaux automatiques
current_dir = os.path.dirname(os.path.abspath(__file__))
input_path = os.path.join(current_dir, "../01_raw_data/01_nettoyage_donnees.csv")
output_path = os.path.join(current_dir, "../02_cleaned_data/machine_failures_clean.csv")
print("\n[START] - Début du contrôle qualité des données...")

# 2. Chargement du dataset industriel
df = pd.read_csv(input_path)

# 3. Traitement et ingénierie des données
# Conversion des températures de Kelvin en degrés Celsius
df['Air_temperature_C'] = df['Air temperature [K]'] - 273.15
df['Process_temperature_C'] = df['Process temperature [K]'] - 273.15
# Création de l'écart thermique entre température du processus et température de l'air
df['Temperature_Delta_C'] = df['Process_temperature_C'] - df['Air_temperature_C']
# Normalisation des noms de colonnes pour SQL, Power BI et DAX
df.rename(columns={
    'Rotational speed [rpm]': 'Rotational_speed_rpm',
    'Torque [Nm]': 'Torque_Nm',
    'Tool wear [min]': 'Tool_wear_min',
    'Machine failure': 'Machine_failure'
}, inplace=True)

# 4. Contrôle des doublons
print("Nombre de doublons avant suppression :", df.duplicated().sum())
# Suppression des doublons si nécessaire
df = df.drop_duplicates()
print("Nombre de doublons après suppression :", df.duplicated().sum())

# 5. Sauvegarde du fichier nettoyé
df.to_csv(output_path, index=False)
print("[OK] Contrôle qualité réussi ! Fichier généré : machine_failures_clean.csv")
print(f"[PATH] Chemin d'accès local : {output_path}\n")

# 6. Diagnostic final du dataset
print("Structure finale du dataset :", df.shape)
print("Valeurs nulles par colonne :")
print(df.isnull().sum())

```